

TP 03 - de la source brute au passage indexable

Université de démonstration - Département d'informatique - module INF-204. Travaux pratiques numéro trois, à réaliser en binôme pendant la séance neuf. Durée prévue : deux heures. Le travail commencé en séance peut être terminé à la maison.

Objectif général. Ce travail pratique fait parcourir à l'étudiant la chaîne complète qui va d'un document PDF brut jusqu'à un passage de texte indexable, c'est-à-dire un fragment de longueur raisonnable, rattaché à sa page d'origine et utilisable par un moteur de recherche sémantique.

Prérequis. Les notions de la séance trois sont supposées acquises : jeux de données, protocole expérimental et mesure des performances. Aucune connaissance préalable des bases de données vectorielles n'est exigée, car les commandes nécessaires figurent dans l'énoncé.

Exercice 1, extraction. À partir du document fourni, extraire le texte page par page et vérifier que le nombre de pages obtenu correspond au nombre de pages annoncé par le lecteur de PDF. Tout écart doit être expliqué dans le compte rendu, en distinguant les pages dépourvues de couche de texte des erreurs de lecture.

Exercice 2, découpage. Découper le texte de chaque page en fragments d'au plus huit cents caractères, avec un recouvrement de cent vingt caractères. Chaque fragment doit conserver un lien vers sa page d'origine et vers le document dont il provient.

Exercice 3, vérification. Mesurer, pour une question portant sur une notion précise du document, le rang auquel le fragment attendu apparaît dans la liste des résultats. Comparer ce rang avec et sans recouvrement des fragments.

Livraison. Un compte rendu de trois pages au maximum, comprenant le protocole retenu, les mesures effectuées et une conclusion sur l'effet du recouvrement. Les scripts utilisés sont joints en annexe.

Modalités de rendu et barème

Rendu. Le compte rendu est déposé au format PDF sur la plateforme du module avant le dimanche soir qui suit la séance. Un seul dépôt par binôme. Les dépôts tardifs ne sont pas acceptés, sauf justification médicale transmise au secrétariat.

Barème. La clarté du protocole compte pour quatre points, la justesse des mesures pour quatre points et la qualité de l'analyse pour deux points. Aucun point n'est attribué pour la longueur du rapport.

Intégrité. Les échanges d'idées entre binômes sont encouragés, mais chaque binôme produit ses propres mesures et rédige son propre compte rendu. Les sources externes utilisées doivent être citées.

Erreurs fréquentes. Comparer deux configurations sur des jeux de données différents, annoncer un rang moyen sans indiquer le nombre de questions testées, oublier de vérifier que les fragments couvrent la totalité du texte du document.