

Université de démonstration - Intelligence artificielle : fondations

Cet ensemble de documents constitue le support écrit du module INF-204, intelligence artificielle : fondations. Il est distribué aux étudiants inscrits et sert de référence unique pour l'ensemble du semestre.

Le cours est découpé en six fascicules indépendants : celui-ci présente la discipline dans son ensemble, et les cinq suivants approfondissent chacun un domaine particulier.

Enseignante : Dre Camille Rousseau - Département d'informatique - semestre de printemps 2026.

Objectifs et modalités d'évaluation

Objectifs pédagogiques. À la fin du module, l'étudiant doit savoir définir l'intelligence artificielle, distinguer l'IA faible de l'IA forte, décrire les trois paradigmes d'apprentissage automatique, formaliser un problème de recherche et choisir une méthode d'évaluation adaptée à un jeu de données donné.

L'évaluation repose sur deux notes. Le contrôle continu compte pour quarante pour cent de la note finale et se compose de deux travaux pratiques notés, réalisés en binôme.

L'examen final écrit compte pour soixante pour cent de la note finale. Il dure deux heures et porte sur l'ensemble du programme, y compris la recherche dans un espace d'états et la logique propositionnelle.

La présence en cours n'est pas notée. Les séances de travaux pratiques ont lieu aux dates fixées au calendrier du semestre et ne sont pas déplacées.

Les six fascicules du module

Fascicule 0, celui-ci : présentation de la discipline, vocabulaire, repères historiques et applications.

Fascicule 1, recherche et planification : formulation d'un problème sous forme d'espace d'états, algorithmes non informés, algorithmes heuristiques, complexité.

Fascicule 2, logique et satisfaisabilité : logique propositionnelle, forme normale conjonctive, procédures de décision, problèmes de satisfaction de contraintes.

Fascicule 3, apprentissage supervisé : modèles de classification et de régression, arbres de décision, forêts aléatoires, machines à vecteurs de support.

Fascicule 4, évaluation et métriques : découpage des données, validation croisée, sur-apprentissage, mesures de performance et comparaison de modèles.

Fascicule 5, réseaux de neurones : du perceptron aux architectures profondes, rétropropagation, convolution, récurrence et mécanismes d'attention.

Bibliographie et ressources

Russell, S. et Norvig, P. - Artificial Intelligence: A Modern Approach, Pearson, quatrième édition, 2020.

Mitchell, T. - Machine Learning, McGraw-Hill, 1997.

Turing, A. M. - Computing Machinery and Intelligence, Mind, volume 59, 1950.

Les diapositives utilisées en cours, les énoncés de travaux pratiques et les corrigés sont disponibles sur la plateforme de l'université. Seuls ces documents font foi pour l'évaluation finale.

Qu'est-ce que l'intelligence artificielle ?

L'intelligence artificielle désigne l'ensemble des techniques informatiques qui permettent à une machine de réaliser des tâches qui, accomplies par un humain, seraient considérées comme requérant de l'intelligence.

On regroupe traditionnellement ces techniques autour de quatre capacités : percevoir un environnement, raisonner sur des connaissances, apprendre à partir d'exemples et agir sur le monde.

Cette définition est volontairement large. Elle inclut aussi bien un programme qui joue aux échecs qu'un système de traduction automatique ou un planificateur industriel.

Une définition par les capacités plutôt que par les mécanismes évite les débats sur la nature exacte de l'intelligence : on demande à un système de réussir une tâche mesurable, pas de ressembler à un humain.

Les sous-domaines de la discipline

Recherche et planification. Trouver une suite d'actions qui mène d'une situation initiale à une situation désirée, dans un espace d'états souvent trop grand pour être parcouru entièrement.

Représentation des connaissances et logique. Décrire des faits et des règles dans un langage formel, puis en déduire de nouveaux faits par des procédures automatiques.

Apprentissage automatique. Extraire des régularités à partir d'exemples plutôt que de les écrire à la main, puis les appliquer à de nouveaux cas.

Perception et langage. Extraire de l'information d'images, de sons ou de textes : vision par ordinateur, reconnaissance de la parole, traitement automatique du langage naturel.

Dans ce module, nous insistons sur la recherche, la logique et l'apprentissage, qui fournissent les fondements des autres sous-domaines.

IA faible et IA forte

L'IA faible, aussi appelée IA étroite, désigne un système conçu pour une tâche précise : jouer aux échecs, reconnaître des visages, traduire un texte ou classer des courriels. Le système n'a aucune compréhension générale et ne fonctionne pas en dehors du domaine pour lequel il a été construit.

L'IA forte, aussi appelée IA générale, désigne un système hypothétique capable de comprendre, d'apprendre et de résoudre n'importe quelle tâche intellectuelle qu'un être humain peut résoudre. Une IA forte aurait des capacités comparables à celles de l'intelligence humaine dans tous les domaines.

Aucun système connu ne constitue une IA forte. Tous les programmes déployés aujourd'hui relèvent de l'IA faible, même lorsque leurs performances dépassent les performances humaines sur une tâche donnée.

La distinction entre IA faible et IA forte sert d'abord d'instrument d'analyse : elle sépare les questions techniques, que l'on peut mesurer, des questions philosophiques, qui portent sur la nature de la compréhension.

Le débat sur la compréhension

Le test de Turing, proposé en 1950, offre un critère opérationnel : si les réponses d'une machine sont indiscernables de celles d'un humain lors d'une conversation, on peut la déclarer intelligente. Ce critère est behavioriste, car il ne regarde que le comportement observable.

John Searle a proposé en 1980 l'expérience de pensée de la chambre chinoise. Une personne enfermée qui manipule des symboles chinois selon un manuel peut produire des réponses correctes sans comprendre un mot de chinois.

L'expérience vise à montrer que la manipulation correcte de symboles ne suffit pas à établir la compréhension. Elle alimente le débat entre les partisans du fonctionnalisme, pour qui l'organisation du traitement importe seule, et ceux qui exigent des états internes dotés d'un contenu.

Nous ne tranchons pas ce débat dans le module. Nous retenons que la question de la compréhension n'est pas réductible à une mesure de performance, alors que les questions techniques de ce cours le sont.

Repères historiques : Turing et le programme initial

En 1950, Alan Turing publie *Computing Machinery and Intelligence* dans la revue *Mind*. L'article pose une question simple : une machine peut-elle penser ? Faute de pouvoir définir la pensée, Turing propose un critère de remplacement.

Il décrit le jeu de l'imitation, que l'on appelle aujourd'hui test de Turing. Un interrogateur dialogue à distance avec un humain et avec une machine. Si, après un temps raisonnable, il ne peut pas distinguer la machine de l'humain, la machine a réussi le test.

L'article discute aussi les objections classiques : l'objection mathématique, l'objection de la conscience et l'objection de l'infini. Ces objections restent discutées aujourd'hui.

Turing estime qu'à la fin du vingtième siècle, une machine disposant d'une mémoire suffisante pourra tromper un interrogateur moyen pendant cinq minutes.

Repères historiques : la conférence de Dartmouth

En 1956, la conférence du Dartmouth Summer Research Project on Artificial Intelligence réunit une dizaine de chercheurs pendant plusieurs semaines. C'est à cette occasion que l'expression intelligence artificielle est proposée par John McCarthy et adoptée par la communauté.

Les participants fondateurs viennent d'horizons variés : mathématiques, logique, psychologie, économie. Cette diversité explique la variété des approches qui coexistent encore aujourd'hui dans la discipline.

La conférence parie sur une progression rapide. Les participants estiment qu'une génération suffira pour résoudre les principaux problèmes. Ce pari sera démenti par les décennies suivantes.

L'optimisme de Dartmouth reste un motif récurrent de la discipline : chaque avancée technique s'accompagne d'annonces de généralisation prochaine.

Repères historiques : les hivers et les reprises

Après un premier élan, la discipline connaît une première période de désaffection entre 1974 et 1980. Les promesses de traduction automatique et de résolution générale de problèmes ne sont pas tenues, et les financements sont interrompus.

Une seconde période de désaffection suit entre 1987 et 1993, liée à l'effondrement du marché des machines spécialisées en logique. Les chercheurs parlent alors de premier et de second hiver de l'intelligence artificielle.

Les succès des années suivantes sont plus discrets mais plus solides : victoire de Deep Blue contre le champion du monde en 1997, percée des réseaux de neurones profonds sur la reconnaissance d'images en 2012.

À partir de 2017, les architectures fondées sur l'attention transforment le traitement du langage. Cette vague s'accompagne d'une croissance forte des ressources de calcul consacrées à l'entraînement des modèles.

Les tendances des années 2020

Trois évolutions structurent la période récente. La première est la mise à l'échelle : les modèles les plus performants croissent en taille et en volume de données, et leurs performances s'améliorent de façon prévisible.

La deuxième est la généralisation d'usage : un même système pré-entraîné sur des textes variés est ensuite adapté à des tâches très différentes, souvent avec peu d'exemples spécifiques.

La troisième est la dépendance aux ressources : l'entraînement de ces modèles mobilise des moyens de calcul considérables, ce qui concentre la recherche dans un petit nombre d'organisations.

Ces évolutions ne changent pas les fondements enseignés dans ce module. Elles en augmentent l'importance pratique : les notions d'évaluation, de biais et de coût des erreurs deviennent des questions industrielles.

Apprentissage automatique : définition

On dit qu'un programme apprend à partir de l'expérience E pour une tâche T et une mesure de performance P si sa performance sur T , mesurée par P , s'améliore avec l'expérience E . Cette formulation, proposée par Mitchell, fixe le vocabulaire du module.

La différence avec la programmation classique tient au mode d'obtention des règles. Un programme classique applique des règles écrites explicitement par un développeur. Un programme qui apprend extrait ces règles à partir d'exemples.

Apprendre n'est pas mémoriser. Un modèle qui restitue les exemples vus ne sert à rien. Ce que l'on attend d'un modèle, c'est la capacité de traiter correctement des cas nouveaux : la capacité de généralisation.

La qualité de la généralisation dépend de trois facteurs : la quantité et la qualité des données, l'adéquation du modèle à la tâche, et la rigueur du protocole d'évaluation.

Les trois paradigmes de l'apprentissage

L'apprentissage supervisé dispose de couples entrée-sortie. Chaque exemple est étiqueté, car on connaît la réponse attendue. Le modèle apprend une fonction qui associe une entrée à une sortie, puis l'applique à de nouvelles entrées.

L'apprentissage non supervisé ne dispose que des entrées, sans étiquette. Le modèle cherche une structure dans les données : groupes d'individus similaires, axes de variation, observations atypiques.

L'apprentissage par renforcement ne dispose ni d'étiquettes ni de couples tout faits. Un agent agit dans un environnement, reçoit une récompense et cherche à maximiser la récompense cumulée. Le modèle apprend donc une politique d'action.

Le choix du paradigme dépend de la forme des données disponibles, et non des préférences de l'équipe. Lorsque les données étiquetées sont rares, l'apprentissage non supervisé est souvent la seule option.

Où l'apprentissage automatique est utilisé

Vision par ordinateur. Détection d'objets, segmentation d'images médicales, contrôle qualité en production industrielle.

Traitement du langage. Traduction automatique, résumé de documents, recherche d'information, analyse de sentiment.

Prédiction tabulaire. Évaluation du risque de crédit, prévision de la demande, maintenance prédictive sur des séries de mesures.

Recommandation et décision séquentielle. Sélection de contenus, affectation de ressources, ordonnancement de tâches.

Dans tous ces domaines, la même démarche revient : formuler la question, rassembler des données représentatives, entraîner, évaluer, surveiller.

Les données au centre du problème

Un modèle n'est jamais meilleur que les données qui l'ont produit. Les statistiques descriptives du jeu d'entraînement déterminent ce que le modèle peut apprendre, et ce qu'il ne peut pas apprendre.

Trois défauts reviennent constamment : la couverture insuffisante de certains cas d'usage, l'étiquetage incohérent entre annotateurs, et la fuite d'information entre les données d'entraînement et celles d'évaluation.

Un jeu de données qui ne représente pas la population cible produit un modèle qui échoue précisément sur les cas minoritaires. C'est la principale source d'écart entre les performances annoncées et les performances observées en production.

Le travail sur les données occupe souvent plus de la moitié du temps d'un projet. Cette proportion n'est pas un signe de mauvaise organisation, mais la réalité du métier.

Limites, risques et responsabilités

Un système d'intelligence artificielle produit des sorties plausibles, pas des vérités. Un modèle peut inventer une information précise et fausse, en particulier lorsqu'il généralise à partir d'un contexte absent de ses données.

L'automatisation d'une décision déplace la responsabilité sans la supprimer. Lorsqu'un système classe, trie ou refuse, il faut pouvoir expliquer la décision, la contester et la corriger.

Les biais présents dans les données se reproduisent dans les décisions. Mesurer la performance globale ne suffit pas : il faut la mesurer par sous-population lorsque la décision a des conséquences sur des personnes.

Enfin, tout système déployé doit être surveillé. La distribution des données d'entrée change avec le temps, et un modèle qui n'est pas réévalué devient progressivement faux sans que rien ne signale l'erreur.

Petit lexique français-anglais

apprentissage supervisé, supervised learning. Apprentissage à partir d'exemples étiquetés.

sur-apprentissage, overfitting. Ajustement excessif aux données d'entraînement, au détriment de la généralisation.

validation croisée, cross-validation. Procédure d'évaluation qui découpe les données en parties et moyenne les scores obtenus.

espace d'états, state space. Ensemble des situations atteignables depuis une situation initiale par une suite d'actions.

forme normale conjonctive, conjunctive normal form. Écriture d'une formule logique comme conjonction de clauses.

Comment travailler ce module

Lire le fascicule avant la séance correspondante, puis refaire les exemples du cours sur papier.

Les notions de ce module s'acquièrent par la pratique du calcul plus que par la lecture.

Faire les travaux pratiques en binôme, mais écrire soi-même le compte rendu. L'écart entre ce que l'on croit avoir compris et ce que l'on sait expliquer est souvent important.

Utiliser le forum du module pour les questions techniques. Une question posée publiquement profite à tout le groupe, et les réponses y restent consultables pendant toute la durée du semestre.

Ne pas confondre familiarité et maîtrise : reconnaître une notion dans un document n'est pas la même chose que savoir quand l'appliquer et quand l'éviter.

Malentendus fréquents

Un réseau de neurones n'est pas plus intelligent qu'un arbre de décision : il est plus souple, ce qui aide sur certains problèmes et nuit sur d'autres. Le bon modèle dépend des données disponibles.

Un score élevé ne prouve rien si le jeu d'évaluation est mal construit. Neuf pour cent d'erreur sur un jeu biaisé reste neuf pour cent d'erreur sur ce jeu, et rien de plus.

Une heuristique n'est pas une approximation approximative : c'est une estimation du cout restant, qui doit satisfaire des propriétés précises pour garantir l'optimalité d'un algorithme de recherche.

Enfin, l'intelligence artificielle n'est pas une discipline récente née avec les modèles de langue : ses questions fondatrices datent des années 1950 et n'ont pas toutes été résolues.

Informations pratiques

L'examen final écrit se déroule pendant la session d'examens de juin 2026. Sa durée est de deux heures et aucun document n'est autorisé, à l'exception d'une feuille de notes manuscrite recto-verso.

Les deux travaux pratiques notés portent sur les jeux de données et l'évaluation, puis sur la recherche dans un espace d'états. Les énoncés sont distribués une semaine avant la séance concernée.

Enseignante : Dre Camille Rousseau - camille.rousseau@universite-demonstration.fr - permanence le mardi de quatorze heures à seize heures, sur rendez-vous pris par courriel.