

Apprentissage supervisé : présentation du fascicule

Ce fascicule décrit les modèles qui apprennent à partir d'exemples étiquetés. C'est la famille de méthodes la plus utilisée en pratique, parce que les problèmes se formulent naturellement sous cette forme.

L'objectif est double : comprendre comment un modèle représente une relation, et savoir choisir un modèle adapté à la taille et à la nature des données disponibles.

Les questions d'évaluation sont traitées dans le fascicule 4. Ici, on suppose que le protocole expérimental est correctement construit et l'on se concentre sur les modèles eux-mêmes.

Le fascicule 5 prolonge ce contenu avec les réseaux de neurones, qui sont des modèles supervisés parmi d'autres.

Le cadre formel

Un problème d'apprentissage supervisé est défini par un espace d'entrée, un espace de sortie et une distribution conjointe inconnue sur les couples entrée-sortie.

L'apprenant reçoit un échantillon fini tiré selon cette distribution. Il choisit une hypothèse dans un ensemble prédéfini, appelé classe d'hypothèses, de manière à minimiser l'erreur attendue sur de nouveaux exemples.

L'erreur attendue ne peut pas être calculée, puisque la distribution est inconnue. On la remplace par un estimateur calculé sur un échantillon, ce qui introduit un écart entre ce que l'on optimise et ce que l'on souhaite.

Toute la théorie de l'apprentissage tourne autour de cet écart : l'erreur empirique mesure la performance sur les exemples vus, et l'erreur de généralisation mesure celle que l'on obtiendra sur des exemples nouveaux.

Classification et régression

En classification, la sortie est une étiquette discrète. Un courriel est indésirable ou non ; une image contient une des dix catégories prévues.

En régression, la sortie est une valeur continue. La consommation d'énergie d'un bâtiment, le prix d'un bien, la concentration d'un polluant en sont des exemples.

La distinction n'est pas seulement technique. Les mesures d'évaluation diffèrent radicalement entre les deux cas, et certaines méthodes ne s'appliquent qu'à l'un des deux.

Rien n'interdit cependant d'aborder un problème de régression par discrétisation, ou un problème de classification par un score continu que l'on seuille ensuite. Ces transformations ont des conséquences sur le protocole.

La question de la représentation

Les données brutes sont rarement utilisables telles quelles. Une observation doit être décrite par un ensemble de variables numériques, appelées variables explicatives ou attributs.

Le choix de cette description détermine ce que le modèle peut apprendre. Aucune méthode ne compense une représentation qui ne contient pas l'information nécessaire.

Les variables catégorielles demandent un encodage explicite : indicatrice pour deux modalités, encodage binaire pour un nombre limité de modalités, ou encodage par fréquence lorsque les modalités sont nombreuses.

Les variables numériques demandent de la prudence sur l'échelle. Un modèle fondé sur des distances réagira très différemment à une variable exprimée en centaines de mètres et à une variable exprimée en millièmes.

Fonctions de perte

La perte mesure l'écart entre la prédiction du modèle et la valeur observée. Le choix de la perte encode l'importance relative des erreurs.

L'erreur quadratique pénalise fortement les grandes erreurs, ce qui la rend sensible aux observations aberrantes. L'erreur absolue traite toutes les erreurs proportionnellement à leur ampleur.

La perte logistique, utilisée en classification, pénalise une prédiction confiante et fausse plus qu'une prédiction hésitante et fausse.

Enfin, la perte peut être asymétrique, c'est-à-dire pénaliser davantage un type d'erreur que l'autre. C'est fréquent lorsque les conséquences des deux erreurs ne sont pas comparables.

Risque empirique, risque réel

Minimiser la perte sur l'échantillon d'entraînement s'appelle la minimisation du risque empirique. C'est une procédure calculable, mais ce n'est pas l'objectif réel.

L'objectif réel est de minimiser l'espérance de la perte sur des exemples inédits, que l'on appelle le risque. L'écart entre les deux décroît avec la taille de l'échantillon, mais lentement.

Une classe d'hypothèses très riche peut atteindre un risque empirique nul tout en ayant un risque réel élevé. C'est le sur-apprentissage, traité en détail dans le fascicule 4.

L'arbitrage entre la richesse de la classe d'hypothèses et l'écart de généralisation est le problème central de l'apprentissage supervisé.

Régression linéaire

Le modèle le plus simple suppose que la sortie est une combinaison affine des variables d'entrée, affectée d'un bruit. Les coefficients sont ajustés pour minimiser la somme des carrés des écarts.

La solution peut être calculée directement par une formule matricielle. Elle existe et est unique lorsque les variables ne sont pas colinéaires.

L'interprétation des coefficients est un avantage important : chaque coefficient mesure l'effet d'une variation unitaire de la variable correspondante, toutes choses égales par ailleurs.

Cette interprétation suppose que les variables sont indépendantes, ce qui est rarement le cas. La colinéarité rend les coefficients instables et leur lecture hasardeuse.

Gradient et taux d'apprentissage

Lorsque la solution directe n'existe pas ou n'est pas calculable, on ajuste les coefficients par descente de gradient : on avance dans la direction opposée au gradient de la perte.

Le taux d'apprentissage contrôle l'amplitude du pas. Un taux trop grand fait osciller la procédure, voire diverger ; un taux trop petit la rend interminablement lente.

Des variantes adaptatives ajustent ce taux automatiquement, en tenant compte de l'historique des gradients. Elles sont aujourd'hui utilisées par défaut dans la plupart des bibliothèques.

Pour un modèle linéaire et une perte quadratique, la fonction de cout est convexe : la descente converge vers l'optimum global. Pour des modèles non linéaires, elle ne converge que vers un optimum local.

Régression logistique

Pour une classification binaire, la régression logistique transforme une combinaison linéaire en probabilité, à l'aide d'une fonction qui écrase la droite réelle dans l'intervalle entre zéro et un.

L'ajustement se fait en maximisant la vraisemblance des étiquettes observées, ce qui revient à minimiser la perte logistique. Le problème est convexe, donc sans optimum local parasite.

Le modèle produit une probabilité, pas seulement une décision. Le seuil de décision est un paramètre séparé, que l'on choisit en fonction du cout relatif des deux types d'erreur.

Cette séparation est souvent négligée. Un modèle bien ajusté avec un seuil mal choisi produit de mauvaises décisions, et inversement.

Frontière de décision

La frontière de décision est l'ensemble des points où le modèle hésite entre les classes. Sa forme détermine la souplesse du modèle.

Un modèle linéaire produit une frontière plane. Un modèle à base de voisinage produit une frontière compliquée, qui épouse la disposition des exemples.

Une frontière très contournée s'ajuste au bruit : elle sépare parfaitement les exemples vus, mais se trompe sur les exemples nouveaux placés près d'elle.

Visualiser la frontière sur deux variables est un exercice utile pour comprendre le comportement d'un modèle avant de l'utiliser sur des données de grande dimension.

Méthode des k plus proches voisins

La méthode des k plus proches voisins ne construit aucun modèle explicite. Pour prédire, elle cherche les k exemples d'entraînement les plus proches de l'observation et agrège leurs étiquettes.

C'est la méthode la plus simple que l'on puisse imaginer, et elle sert de référence : un modèle sophistiqué qui ne fait pas mieux qu'elle n'apporte rien.

Elle souffre de deux défauts. La prédiction coûte le parcours de tout l'entraînement, et le résultat dépend fortement du choix de la distance et du nombre de voisins.

Elle est aussi sensible à la dimension : dans un espace à grande dimension, toutes les distances se ressemblent, et la notion de voisinage perd son sens.

Classification naïve de Bayes

Cette méthode applique la règle de Bayes en supposant que les variables sont conditionnellement indépendantes étant donnée la classe. L'hypothèse est presque toujours fausse.

Malgré cela, la méthode obtient de bons résultats sur de nombreux problèmes de classification de textes. Sa simplicité et sa rapidité d'entraînement en font un point de comparaison utile.

Elle produit des probabilités mal calibrées, souvent proches de zéro ou de un. L'ordre des scores reste exploitable, mais leur valeur numérique doit être interprétée avec prudence.

L'hypothèse d'indépendance explique aussi ses erreurs systématiques : deux variables fortement corrélées voient leur influence comptée deux fois.

Arbres de décision

Un arbre de décision pose une suite de questions sur les variables. Chaque noeud interne teste une variable, chaque branche correspond à une réponse et chaque feuille porte une prédiction.

La construction choisit à chaque noeud la variable qui sépare le mieux les classes. Les critères les plus utilisés sont le gain d'information, fondé sur l'entropie, et l'indice de Gini.

Le gain d'information mesure la réduction d'incertitude produite par le test. L'indice de Gini mesure la probabilité de mal classer un exemple tiré au hasard dans le noeud ; il est légèrement plus rapide à calculer.

Les deux critères conduisent le plus souvent à des arbres similaires. Le choix entre eux importe moins que la profondeur maximale et la taille minimale des feuilles.

Contrôler la taille d'un arbre

Un arbre développé jusqu'au bout sépare parfaitement les exemples d'entraînement, y compris les observations aberrantes. Son erreur de généralisation est mauvaise.

L'élagage consiste à supprimer des branches après construction, en comparant l'erreur de validation avant et après la suppression.

Les critères d'arrêt anticipé limitent la profondeur, le nombre minimal d'exemples par feuille ou l'amélioration minimale exigée pour poursuivre une division.

Ces paramètres se règlent par validation, jamais sur le jeu de test. Un arbre réglé sur le jeu de test perd toute valeur d'estimation.

Bagging et forêts aléatoires

Le bagging entraîne plusieurs modèles sur des échantillons tirés avec remise, puis moyenne leurs prédictions. La moyenne réduit la variance sans augmenter le biais de façon notable.

La forêt aléatoire applique cette idée aux arbres, en ajoutant une seconde source d'aléa : à chaque division, seules quelques variables tirées au hasard sont considérées.

Cette double randomisation décorrèle les arbres. Sans elle, tous les arbres seraient presque identiques et leur moyenne n'apporterait rien.

Les forêts aléatoires sont parmi les méthodes les plus fiables sur données tabulaires. Elles fournissent en outre une mesure d'importance des variables, calculée à partir de la contribution de chacune aux divisions.

Méthodes d'ensemble par boosting

Le boosting combine des modèles faibles en les entraînant séquentiellement. Chaque nouveau modèle se concentre sur les exemples mal prédits par les précédents.

L'algorithme AdaBoost, proposé en 1995, pondère les exemples et combine les modèles par un vote pondéré. Il offre des garanties théoriques sur l'erreur d'entraînement.

Les méthodes de gradient boosting reformulent l'idée comme une descente de gradient dans l'espace des fonctions : chaque nouveau modèle approxime le gradient de la perte.

Ces méthodes dominent les compétitions sur données tabulaires. Elles sont plus sensibles aux hyperparamètres que les forêts aléatoires, et demandent un réglage plus soigneux.

Machines à vecteurs de support

Parmi tous les hyperplans qui séparent deux classes, la machine à vecteurs de support choisit celui qui maximise la marge, c'est-à-dire la distance minimale aux exemples.

Seuls les exemples situés sur la frontière de la marge, appelés vecteurs de support, déterminent la solution. Déplacer un exemple éloigné ne change rien au résultat.

Une version relâchée autorise quelques exemples à violer la marge, ce qui est indispensable lorsque les classes ne sont pas séparables. Un paramètre contrôle le compromis entre marge large et violations acceptées.

La méthode est sensible à l'échelle des variables : sans normalisation préalable, une variable exprimée dans une grande unité domine la distance et donc la solution.

Noyaux et frontières non linéaires

L'astuce du noyau consiste à calculer des produits scalaires dans un espace de dimension supérieure sans jamais y projeter explicitement les données.

Cela permet d'obtenir des frontières non linéaires tout en conservant la formulation d'origine. Le noyau gaussien, fondé sur une distance, est le plus utilisé.

Le choix du noyau et de ses paramètres remplace alors le choix des variables. Un noyau trop souple produit le même effet qu'un modèle trop complexe.

Sur des données de taille modérée, une machine à vecteurs de support reste une option solide. Sur de très grands volumes, son coût de calcul devient dissuasif.

Passer de deux classes à plusieurs

La plupart des classifieurs sont conçus pour deux classes. Pour traiter k classes, on combine plusieurs problèmes binaires.

La stratégie un contre tous entraîne k classifieurs, chacun séparant une classe des autres. Elle est simple, mais chaque classifieur voit un problème déséquilibré.

La stratégie un contre un entraîne un classifieur par paire de classes, soit k fois k moins un sur deux classifieurs, puis décide par vote. Chacun traite un problème équilibré, mais leur nombre croît quadratiquement.

Certaines méthodes, comme la régression logistique multinomiale ou les arbres, gèrent nativement plusieurs classes. Les utiliser évite l'artifice du vote.

Classes déséquilibrées

Lorsqu'une classe représente une fraction infime des exemples, l'exactitude devient trompeuse. Un modèle qui prédit toujours la classe majoritaire obtient un excellent score.

Trois familles de remèdes existent. Modifier les données, en suréchantillonnant la classe minoritaire ou en sous-échantillonnant la majoritaire. Modifier la perte, en pondérant davantage les erreurs sur la classe minoritaire. Modifier le seuil de décision, en le déplaçant vers la classe majoritaire.

Ces remèdes modifient l'équilibre entre précision et rappel, sans améliorer la capacité du modèle. Ils doivent être évalués avec les mesures du fascicule 4, jamais avec l'exactitude seule.

Regroupement par k-moyennes

La méthode des k-moyennes partitionne les données en k groupes en minimisant la somme des distances des points au centre de leur groupe.

L'algorithme alterne deux étapes : assigner chaque point au centre le plus proche, puis recalculer chaque centre comme la moyenne de son groupe. Il converge vers un minimum local.

Le résultat dépend de l'initialisation. La pratique courante est de répéter l'algorithme avec plusieurs initialisations et de conserver la meilleure partition.

Le nombre de groupes doit être fixé à l'avance ou choisi par des critères externes. Aucune méthode automatique ne le détermine de façon fiable sans connaissance du problème.

Autres méthodes de regroupement

Le regroupement hiérarchique construit un arbre de fusions successives, du plus fin au plus grossier. Le résultat se lit sur un dendrogramme, qui montre la structure à toutes les échelles.

La méthode DBSCAN, proposée en 1996, définit les groupes comme des régions denses séparées par des régions creuses. Elle détecte en outre les points isolés, qu'aucun groupe ne contient.

Son avantage principal est de ne pas exiger le nombre de groupes. En revanche, elle dépend de deux paramètres de densité, difficiles à fixer lorsque les échelles varient d'une région à l'autre.

Le choix entre ces méthodes dépend de la forme attendue des groupes : sphériques, hiérarchiques ou de densité variable.

Réduction de dimension

L'analyse en composantes principales projette les données sur les directions de variance maximale. Elle est calculable directement par une décomposition matricielle.

Sa principale vertu est la visualisation : projeter des données de plusieurs dizaines de variables sur deux axes permet de repérer des groupes et des observations aberrantes.

Elle est aussi utilisée en préparation, pour réduire le nombre de variables avant un modèle sensible à la dimension. Attention toutefois : les composantes obtenues sont des combinaisons de toutes les variables d'origine et perdent leur interprétation.

Des variantes non linéaires existent, au prix d'un cout de calcul plus élevé et d'un réglage supplémentaire.

Détection d'anomalies

La détection d'anomalies cherche les observations qui s'écartent du comportement habituel. Elle est utilisée pour la fraude, la maintenance et la surveillance de systèmes.

Le cadre est difficile parce que les anomalies sont rares et mal définies. L'étiquetage est souvent absent, ce qui rapproche le problème de l'apprentissage non supervisé.

Les approches usuelles modélisent la normalité, puis signalent comme anomalie tout point dont la vraisemblance est faible. La qualité dépend entièrement de la représentation des données normales.

Comme pour les classes déséquilibrées, l'évaluation exige des mesures adaptées : précision et rappel à un seuil donné, plutôt qu'exactitude globale.

Construire et sélectionner les variables

La construction de variables consiste à créer, à partir des données brutes, des descriptions plus directement utiles au modèle : ratios, écarts à une moyenne de référence, comptages sur une fenêtre glissante.

Cette étape demande une connaissance du domaine plus qu'une connaissance des algorithmes. Elle reste l'un des leviers les plus efficaces sur les données tabulaires.

La sélection de variables vise l'inverse : retirer les variables inutiles ou redondantes, pour réduire le bruit et le coût de calcul.

Les méthodes de filtrage classent les variables par un critère statistique indépendant du modèle. Les méthodes d'enveloppe évaluent un sous-ensemble de variables en entraînant réellement le modèle, ce qui est plus coûteux mais plus fiable.

Choisir les hyperparamètres

Les hyperparamètres sont les paramètres fixés avant l'entraînement : profondeur d'un arbre, nombre de voisins, force de la régularisation.

La recherche exhaustive évalue toutes les combinaisons d'une grille prédéfinie. Elle est fiable mais coûteuse dès que le nombre d'hyperparamètres augmente.

La recherche aléatoire explore des combinaisons tirées au hasard. Elle est souvent plus efficace, car peu d'hyperparamètres influencent réellement le résultat.

Les méthodes bayésiennes construisent un modèle de la performance en fonction des hyperparamètres et choisissent les essais suivants en conséquence. Elles réduisent le nombre d'entraînements nécessaires.

Du prototype à la production

Un modèle entraîné n'est pas un système. Il faut fixer le seuil de décision, définir le comportement lorsque les données d'entrée sont incomplètes ou inattendues, et prévoir un mode de secours.

La surveillance en production ne se limite pas à mesurer le temps de réponse. Il faut suivre la distribution des entrées et, lorsque des étiquettes arrivent avec retard, la performance réelle du modèle.

Un modèle se dégrade sans que personne ne change rien, parce que le monde change. Réentraîner périodiquement est une nécessité opérationnelle, pas une amélioration optionnelle.

Enfin, chaque décision automatisée doit rester contestable. Cela suppose de conserver la version du modèle, les données utilisées et la trace de la décision.

Ce qu'il faut retenir de ce fascicule

Un modèle supervisé ajuste les paramètres d'une classe d'hypothèses pour minimiser une perte empirique. Ce que l'on veut vraiment minimiser est le risque, que l'on ne peut qu'estimer.

Le choix du modèle dépend de la taille des données, de la nature des variables et du besoin d'interprétation. Un arbre lisible peut valoir mieux qu'un modèle plus précis mais inexplicable.

Sur données tabulaires de taille modérée, les ensembles d'arbres sont les méthodes les plus fiables. Les machines à vecteurs de support restent solides lorsque les dimensions sont nombreuses.

Enfin, aucune méthode ne compense une représentation inadéquate ni un protocole d'évaluation mal construit. Ces deux points pèsent plus lourd que le choix de l'algorithme.

Exercices du fascicule 3

Exercice 1. Sur un jeu de données tabulaire fourni, comparer une régression logistique, un arbre de décision et une forêt aléatoire. Rapporter les scores de validation et le temps d'entraînement de chacun.

Exercice 2. Faire varier la profondeur maximale de l'arbre et tracer la courbe du score d'entraînement et celle du score de validation en fonction de ce paramètre.

Exercice 3. Comparer la méthode des k plus proches voisins avec et sans normalisation des variables. Expliquer l'écart observé.

Exercice 4. Sur un problème à trois classes déséquilibrées, comparer l'exactitude et la mesure F1 par classe, avant et après repondération de la perte.