

Évaluation et métriques : présentation du fascicule

Un modèle qui obtient un bon score n'est pas nécessairement un bon modèle. Ce fascicule traite la question qui décide de la valeur d'un résultat : comment le mesurer.

Les erreurs de protocole sont les plus coûteuses d'un projet d'apprentissage, parce qu'elles produisent des chiffres crédibles et faux. Elles ne se voient ni dans les courbes, ni dans les journaux d'exécution.

Ce fascicule présente les protocoles d'évaluation, les mesures usuelles, et les précautions qui séparent une expérience reproductible d'une démonstration d'apparence.

Il ne traite pas de la mise en production, sinon par les conséquences de l'évaluation sur la surveillance d'un modèle déployé.

Pourquoi l'évaluation est le problème central

Un modèle n'a pas de valeur en lui-même : sa valeur dépend de ce qu'il sait faire sur des données qu'il n'a jamais vues, et de la manière dont ce résultat a été établi.

Deux projets peuvent annoncer la même exactitude et n'avoir aucune valeur comparable. L'un aura évalué sur un jeu représentatif, l'autre sur un jeu facile ou partiellement présent dans l'entraînement.

La reproductibilité dépend de détails rarement documentés : la graine aléatoire, l'ordre des exemples, la version des bibliothèques, la manière de traiter les valeurs manquantes.

Décrire précisément la procédure est donc une exigence, pas une coquetterie rédactionnelle. Un résultat sans protocole n'est pas un résultat.

Le découpage en trois parties

Le jeu d'entraînement sert à ajuster les paramètres du modèle. Le jeu de validation sert à choisir les hyperparamètres et à comparer les variantes. Le jeu de test sert à estimer la performance finale.

Les proportions usuelles sont de soixante-dix, quinze et quinze pour cent. Ces valeurs ne sont pas des règles : avec peu de données, on augmente la part de validation ; avec beaucoup de données, on peut se contenter d'un pour cent pour les deux derniers.

Le jeu de test est utilisé une seule fois, à la fin du projet. Chaque décision prise en regardant les scores de test consomme une partie de sa valeur d'estimation.

La distinction entre décider et informer est la règle la plus souvent violée. Le jeu de validation sert à décider, le jeu de test sert à informer.

Comment découper correctement

Le découpage aléatoire simple suppose que les exemples sont indépendants et identiquement distribués. C'est rarement le cas lorsque les observations proviennent d'individus suivis dans le temps.

Lorsque plusieurs observations concernent le même individu, il faut découper par individu. Sinon, le même sujet apparaît dans l'entraînement et dans le test, et la performance annoncée est trop optimiste.

Lorsque les données sont temporelles, il faut découper par date : entraîner sur le passé, évaluer sur le futur. Un découpage aléatoire mélange les deux et autorise le modèle à lire l'avenir.

Ces règles ne relèvent pas de la statistique mais de la connaissance du dispositif de collecte. Aucun outil automatique ne les applique à votre place.

Les fuites de données

Une fuite de données survient lorsque de l'information du jeu de test influence l'entraînement. Elle produit des scores excellents qui ne se reproduisent pas en production.

Fuite par prétraitement. Calculer la moyenne et l'écart-type sur l'ensemble des données, puis normaliser, fait entrer de l'information de test dans l'entraînement. Les statistiques de normalisation doivent être calculées sur le seul jeu d'entraînement.

Fuite par variable. Une variable calculée après la décision, ou contenant une partie de la réponse, produit un modèle parfaitement inutile mais très performant.

Fuite par répétition. Des quasi-doublons répartis entre entraînement et test transforment l'évaluation en exercice de mémorisation. Un contrôle de duplication avant découpage est indispensable.

La validation croisée

La validation croisée découpe les données en k parties. On entraîne k fois le modèle, en réservant à chaque fois une partie différente pour l'évaluation, puis on moyenne les k scores obtenus.

La variante stratifiée conserve la proportion des classes dans chaque partie. Elle est indispensable lorsque les classes sont déséquilibrées, sinon certaines parties peuvent ne contenir aucun exemple d'une classe.

La variante par groupes respecte une structure d'appartenance : tous les exemples d'un même groupe restent du même côté du découpage.

La variante temporelle fait glisser la fenêtre d'entraînement vers le futur. Elle est la seule acceptable sur des séries chronologiques.

Combien de parties, et pourquoi

La valeur usuelle est cinq ou dix. Une valeur élevée réduit le biais de l'estimation, parce que chaque modèle voit davantage de données, mais augmente le coût de calcul et la variance entre répétitions.

L'extrême est la validation croisée dite à un exemple laissé de côté : chaque exemple sert une fois de test. Elle est presque sans biais, mais très coûteuse et de variance élevée sur des petits jeux.

Sur des jeux déséquilibrés ou de petite taille, on répète la validation croisée avec des découpages différents et l'on moyenne l'ensemble. Ce sont ces répétitions qui stabilisent l'estimation.

Enfin, la validation croisée sert à comparer des modèles et à choisir des hyperparamètres. Elle ne remplace pas le jeu de test, sauf si l'on a renoncé à toute estimation finale indépendante.

Sur-apprentissage et sous-apprentissage

Le sur-apprentissage survient lorsqu'un modèle apprend par coeur les particularités du jeu d'entraînement, y compris son bruit. Le score d'entraînement devient excellent tandis que le score de validation se dégrade.

Le sous-apprentissage survient à l'inverse lorsqu'un modèle est trop simple pour représenter la relation étudiée. Les deux scores restent mauvais.

Ces deux régimes se reconnaissent à l'écart entre les deux courbes. Un écart faible avec des scores médiocres indique un sous-apprentissage ; un écart important indique un sur-apprentissage.

Les remèdes au sur-apprentissage sont l'augmentation du volume de données, la régularisation, la réduction du nombre de variables et l'arrêt précoce de l'entraînement.

Le compromis biais-variance

L'erreur attendue d'un modèle se décompose en trois termes : le biais, la variance et le bruit irréductible des données.

Le biais mesure l'écart systématique entre la prédiction moyenne du modèle et la vérité. La variance mesure la sensibilité du modèle à l'échantillon d'entraînement particulier qui lui a été fourni.

Un modèle trop simple a un biais élevé et une variance faible. Un modèle trop complexe a l'inverse. La complexité optimale se situe entre les deux.

Ce compromis est un cadre d'analyse, pas une recette. Il explique pourquoi ajouter des données aide un modèle à variance élevée et n'aide pas un modèle à biais élevé.

Lire les courbes d'apprentissage

Une courbe d'apprentissage trace le score d'entraînement et le score de validation en fonction du volume de données d'entraînement.

Si les deux courbes convergent vers un score médiocre, le modèle manque de capacité ou les variables décrivent mal le problème : ajouter des données n'aidera pas.

Si un écart persiste entre les deux courbes, le modèle a trop de capacité pour la quantité de données disponibles. Ajouter des données, ou réduire la complexité, sont les deux remèdes.

Une seconde variante trace les scores en fonction de la complexité du modèle. Les deux lectures se complètent, et leur combinaison permet de choisir entre plus de données et un modèle plus simple.

Régularisation

La régularisation ajoute à la perte un terme qui pénalise la complexité du modèle. Elle limite mécaniquement la variance, au prix d'un biais supplémentaire.

La pénalité quadratique, dite de ridge, contracte les coefficients vers zéro sans les annuler. Elle stabilise les estimations lorsque les variables sont corrélées.

La pénalité absolue, dite lasso, proposée en 1996, annule certains coefficients exactement. Elle produit donc un modèle plus parcimonieux, utile lorsque beaucoup de variables sont inutiles.

Un paramètre contrôle l'intensité de la pénalité. Il se choisit par validation, sur la même grille que les autres hyperparamètres.

La matrice de confusion

Pour une classification binaire, la matrice de confusion croise les étiquettes réelles et les prédictions, et dénombre quatre cas : vrais positifs, faux positifs, vrais négatifs et faux négatifs.

Toutes les mesures usuelles s'expriment à partir de ces quatre nombres. Afficher la matrice avant les scores évite bien des malentendus.

La matrice se généralise aux problèmes multi-classes : elle devient un tableau de taille k fois k , où l'on lit surtout la diagonale et les confusions les plus fréquentes hors diagonale.

Les confusions entre classes ne sont pas symétriques. Savoir quelles classes sont confondues, et dans quel sens, oriente souvent mieux les améliorations qu'un score global.

Précision, rappel et mesure F1

La précision rapporte les vrais positifs aux prédictions positives. Elle répond à la question : parmi les cas signalés, quelle proportion l'était réellement ?

Le rappel rapporte les vrais positifs aux positifs réels. Il répond à la question : parmi les cas à détecter, quelle proportion a été trouvée ?

La mesure F1 est la moyenne harmonique des deux. Elle pénalise fortement les déséquilibres : un modèle avec une précision de un et un rappel de zéro obtient une mesure F1 de zéro.

Le choix entre privilégier la précision ou le rappel dépend du coût des erreurs. Manquer un courriel indésirable se paie en désagrément ; manquer une lésion se paie autrement.

Courbe précision-rappel

Un classifieur produit un score, et le seuil transforme ce score en décision. En faisant varier le seuil, on obtient une famille de couples précision-rappel.

La courbe précision-rappel montre ce compromis. Sur des classes très déséquilibrées, elle est plus informative que la courbe ROC.

L'aire sous cette courbe, ou précision moyenne, résume la performance sur l'ensemble des seuils. Elle sert de mesure de référence lorsque la classe positive est rare.

Comparer deux modèles sur cette courbe demande de la prudence : deux courbes peuvent se croiser, et aucun modèle n'est alors uniformément meilleur.

Courbe ROC et aire sous la courbe

La courbe ROC trace le taux de vrais positifs contre le taux de faux positifs, en faisant varier le seuil de décision. Elle provient des travaux de détection de signal des années 1940.

L'aire sous cette courbe s'interprète comme la probabilité qu'un positif tiré au hasard reçoive un score supérieur à un négatif tiré au hasard.

Sa valeur est indépendante du seuil et de la prévalence des classes, ce qui est à la fois un avantage et un piège : un modèle peut avoir une aire excellente et être inutilisable au seuil requis.

La diagonale correspond à un classifieur aléatoire, d'aire un demi. Une aire inférieure à un demi indique une inversion systématique des scores, pas nécessairement un modèle sans information.

Choisir un seuil

Le seuil de décision n'est pas un paramètre du modèle mais une décision opérationnelle, qui dépend du cout relatif des deux erreurs et de la capacité de traitement disponible.

Une méthode courante consiste à fixer le seuil qui atteint un rappel cible, puis à mesurer la précision obtenue. L'inverse est possible lorsque le cout des faux positifs domine.

Sur des données déséquilibrées, le seuil optimal est souvent éloigné de la valeur neutre. Utiliser la valeur par défaut de la bibliothèque est une source fréquente de contre-performance en déploiement.

Le seuil se choisit sur le jeu de validation, jamais sur le jeu de test, et il doit être réévalué lorsque la population change.

Calibration des probabilités

Un modèle peut classer correctement tout en produisant des probabilités mal calibrées. Un score de zéro virgule neuf n'a de sens que si, parmi les cas ainsi notés, environ quatre-vingt-dix pour cent sont effectivement positifs.

La courbe de fiabilité compare, par tranche de score, la probabilité annoncée et la fréquence observée. Une courbe au-dessus de la diagonale indique une sous-confiance.

Le score de Brier combine calibration et pouvoir discriminant en une seule valeur. Il se décompose en trois termes, dont deux correspondent à la calibration et à la résolution.

La régression logistique et les méthodes d'ensemble par boosting produisent généralement des probabilités acceptables. Les machines à vecteurs de support et les forêts aléatoires demandent une correction par une procédure dédiée.

Mesures pour la régression

L'erreur absolue moyenne exprime l'écart en unités de la variable prédite. Elle est directement interprétable et peu sensible aux valeurs extrêmes.

L'erreur quadratique moyenne pénalise davantage les grandes erreurs. Sa racine s'exprime dans la même unité que la variable prédite, ce qui la rend lisible.

Le coefficient de détermination rapporte la variance expliquée à la variance totale. Il est utile pour comparer des modèles sur une même échelle, mais il peut être négatif lorsque le modèle fait moins bien qu'une simple moyenne.

Comparer deux modèles sur ces mesures suppose le même découpage et la même définition des erreurs. Ce n'est pas toujours le cas dans la littérature publiée.

Mesures multi-classes

La moyenne macro calcule la mesure pour chaque classe, puis en fait la moyenne simple. Chaque classe pèse le même poids, quelle que soit sa fréquence.

La moyenne micro agrège d'abord les dénombrements de toutes les classes, puis applique la formule. Les classes fréquentes pèsent alors davantage.

La moyenne pondérée par la fréquence des classes se situe entre les deux. Avec des classes équilibrées, les trois coïncident.

Annoncer une seule de ces valeurs sans préciser laquelle est une omission significative. Sur un jeu déséquilibré, l'écart entre macro et micro peut dépasser vingt points.

Estimer l'incertitude d'un score

Un score calculé sur un échantillon est une estimation, pas une valeur exacte. Sa variabilité dépend de la taille de l'échantillon et de la proportion observée.

L'intervalle de confiance donne une fourchette plausible. Deux modèles dont les intervalles se recouvrent largement ne sont pas distinguables par l'expérience réalisée.

Le rééchantillonnage par bootstrap, décrit par Efron en 1979, estime cette variabilité sans hypothèse de distribution : on tire de nombreux échantillons avec remise et l'on observe la dispersion du score.

C'est indispensable pour les mesures non linéaires, comme la mesure F1 ou la précision moyenne, pour lesquelles aucune formule simple n'existe.

Comparer deux modèles

Comparer deux modèles sur une seule valeur est insuffisant. L'écart observé peut être entièrement attribuable à la variabilité du découpage.

La pratique de référence consiste à répéter l'expérience avec plusieurs découpages et à comparer les scores appariés, c'est-à-dire calculés sur les mêmes partitions.

Un test de comparaison apparié évalue si l'écart moyen est compatible avec l'hypothèse d'absence de différence. Il ne dit rien sur l'importance pratique de cet écart.

Un écart statistiquement significatif de zéro virgule deux point n'a aucun intérêt opérationnel. La significativité et l'utilité sont deux questions distinctes.

Choisir une référence de comparaison

Un modèle doit toujours être comparé à une référence simple. La plus utile est la prédiction la plus fréquente, qui donne le score à battre pour établir qu'un modèle a appris quelque chose.

Une seconde référence utile est la règle métier appliquée aujourd'hui, lorsqu'elle existe. Battre une référence statistique ne suffit pas si le système en place fait mieux.

Sur certaines familles de problèmes, une méthode publiée sert de point de comparaison. Reproduire ce résultat avant de proposer une amélioration évite les comparaisons avec la littérature qui ne tiennent pas.

Enfin, un modèle simple entraînable en quelques secondes doit être essayé avant les méthodes complexes. Il sert de plancher et permet de détecter immédiatement un problème de données.

Rapporter les résultats honnêtement

Indiquer le découpage, les proportions, la graine aléatoire et la procédure de sélection des modèles. Ces informations conditionnent la reproduction du résultat.

Rapporter la dispersion, pas seulement la moyenne. Un score de quatre-vingt-dix pour cent avec un intervalle large et un score de quatre-vingt-huit pour cent stable ne conduisent pas à la même décision.

Rapporter les échecs. Un modèle qui échoue sur une sous-population identifiée est plus utile qu'un score global sans analyse, parce qu'il indique où porter l'effort.

Éviter la sélection du meilleur résultat parmi de nombreux essais. Comparer cinquante configurations sur le jeu de test puis rapporter la meilleure consomme le jeu de test et produit une estimation biaisée.

Évaluer après la mise en production

Les performances mesurées avant déploiement ne se reproduisent pas automatiquement. La population change, les capteurs dérivent, les usages évoluent.

La dérive de données désigne un changement de distribution des entrées. La dérive de concept désigne un changement de la relation entre entrées et sortie. La seconde est invisible sans étiquettes récentes.

La surveillance compare en continu les distributions observées à celles de l'entraînement, et suit les scores dès que les étiquettes deviennent disponibles.

Un modèle déployé sans surveillance n'est pas évalué : il est supposé bon. Cette hypothèse est fausse dès que l'environnement change.

Ce qu'il faut retenir de ce fascicule

Le protocole d'évaluation fait partie du résultat. Un score sans protocole n'est pas interprétable, et un protocole comportant une fuite produit des chiffres flatteurs et faux.

Le découpage doit respecter la structure des données : groupes, individus, ordre temporel. Aucun outil ne peut le deviner à la place du praticien.

Le choix de la mesure dépend du cout des erreurs et du déséquilibre des classes. L'exactitude seule est presque toujours une mauvaise mesure.

Enfin, comparer deux modèles exige de répéter l'expérience et de rapporter la dispersion. Un écart plus petit que la variabilité de la mesure n'est pas un résultat.

Exercices du fascicule 4

Exercice 1. Construire un découpage qui provoque une fuite de données, mesurer le score obtenu, puis corriger le découpage et comparer les deux scores.

Exercice 2. Calculer la précision, le rappel et la mesure F1 pour un seuil donné, puis tracer la courbe précision-rappel complète sur un jeu de données fourni.

Exercice 3. Estimer par rééchantillonnage l'intervalle de confiance d'une mesure F1, puis comparer deux modèles dont les intervalles se recouvrent partiellement.

Exercice 4. Comparer la moyenne macro et la moyenne micro d'une même mesure sur un jeu à trois classes déséquilibrées, et expliquer l'écart obtenu.